Otimização Multiobjetivo de Monitoramento de Ativos

Entrega #2 – Ferramenta de Otimização: Algoritmo de Solução

Pedro Nunes Fabio Xavier Djalma Junior Nikolas Barbosa
Pedro Marinho

EEE910 – Otimização Multiobjetivo

Outubro de 2026

Resumo

Esta entrega discute e justifica a escolha do algoritmo de solução e das ferramentas computacionais para o modelo de Programação Linear Inteira Binária Multiobjetivo formulado na Entrega #1 (Monitoramento de Ativos). Dada a natureza estritamente discreta e limitada do segundo objetivo (número de equipes $f_2 \in \{1, \ldots, 8\}$), recomenda-se o método ε-restrito acoplado a ferramentas de Programação Linear Inteira Mista (MILP) como abordagem principal exata para a determinação completa da fronteira de Pareto. Como método metaheurístico comparativo, propõe-se o algoritmo evolutivo NSGA-II com representação inteira-discreta e tratamento de restrições de capacidade mínima ($L = 4$ ativos por equipe). Essa entrega constitui apenas a apresentação das ferramentas utilizadas, não apresentando os resultados computacionais obtidos até então.

1 Problema de otimização considerado

Na Entrega #1, o problema de monitoramento de ativos foi formulado como a decisão simultânea de alocar equipes de manutenção entre bases disponíveis e atribuir cada ativo a uma base ocupada e a uma equipe responsável. Considere os conjuntos de ativos $I = \{1, \ldots, n\}$ com $n = 125$, bases de manutenção $J = \{1, \ldots, m\}$ com $m = 14$, e equipes potenciais $K = \{1, \ldots, s\}$ com $s = 8$. A distância entre o ativo $i \in I$ e a base $j \in J$ é dada pelo parâmetro conhecido d_{ij}, totalizando $125 \times 14 = 1.750$ combinações ativo-base.

As variáveis de decisão binárias compreendem: $x_{ij} \in \{0, 1\}$ (1 se o ativo i for atribuído à base j; 0 caso contrário), $y_{jk} \in \{0, 1\}$ (1 se a equipe k estiver alocada à base j; 0 caso contrário) e $h_{ik} \in \{0, 1\}$ (1 se o ativo i for mantido pela equipe k; 0 caso contrário), perfazendo $1.750 + 112 + 1.000 = 2.862$ variáveis binárias. Busca-se minimizar simultaneamente a distância total de deslocamento base-ativo e o número total de equipes empregadas:

$$\min \quad f_1(x) = \sum_{i \in I} \sum_{j \in J} d_{ij} x_{ij}, \tag{1}$$

$$\min \quad f_2(y) = \sum_{j \in J} \sum_{k \in K} y_{jk}. \tag{2}$$

As restrições operacionais definidas na Entrega #1 asseguram a consistência das alocações:

$$\sum_{j\in J} y_{jk} \le 1, \qquad \forall k \in K, \tag{3}$$

$$\sum_{j\in J} x_{ij} = 1, \qquad \forall i \in I, \tag{4}$$

$$x_{ij} \le \sum_{k\in K} y_{jk}, \qquad \forall i \in I,\ \forall j \in J, \tag{5}$$

$$\sum_{k\in K} h_{ik} = 1, \qquad \forall i \in I, \tag{6}$$

$$h_{ik} \le \sum_{j\in J} y_{jk}, \qquad \forall i \in I,\ \forall k \in K, \tag{7}$$

$$h_{ik} + y_{jk} \le 1 + x_{ij}, \qquad \forall i \in I,\ \forall j \in J,\ \forall k \in K, \tag{8}$$

$$\sum_{i\in I} h_{ik} \ge L \sum_{j\in J} y_{jk}, \qquad \forall k \in K, \tag{9}$$

$$\sum_{j\in J}\sum_{k\in K} y_{jk} \le 8, \tag{10}$$

$$x_{ij}, y_{jk}, h_{ik} \in \{0,1\}, \qquad \forall i \in I,\ \forall j \in J,\ \forall k \in K. \tag{11}$$

O parâmetro L na restrição (9) estabelece a cota mínima de ativos por equipe ativa, calculada a partir do percentual $\eta = 0,2$:

$$L = \left\lceil \frac{\eta n}{s} \right\rceil = \left\lceil \frac{0,2 \cdot 125}{8} \right\rceil = \lceil 3,125 \rceil = 4. \tag{12}$$

Neste modelo, a ordem sequencial de visita aos ativos não é considerada, o que evita a explosão combinatória fatorial (da ordem de $n!$) comum em problemas com roteamento. A formulação caracteriza-se estritamente como um problema de alocação e localização de recursos sujeito a restrições de capacidade mínima. Além disso, em configurações nas quais não há repetição de bases por múltiplas equipes ($\sum_{k\in K} y_{jk} \le 1$), o espaço de configurações de bases resume-se à soma das combinações simples de até $s = 8$ bases dentre $m = 14$:

$$N_{\text{comb}} = \sum_{\varepsilon=1}^{8} \binom{14}{\varepsilon} = 14 + 91 + 364 + 1.001 + 2.002 + 3.003 + 3.432 + 3.003 = 12.910. \tag{13}$$

Ainda que o número de subconjuntos de bases seja moderado, a presença da cota mínima de $L = 4$ ativos por equipe em (9) impede a simples atribuição de cada ativo à base ativa mais próxima: se uma base geograficamente isolada atrair menos de quatro ativos, a configuração inteira requer realocação de ativos vizinhos ou descarte da base, justificando o emprego de otimizadores estruturados.

2 Critérios para escolha do algoritmo

A seleção da ferramenta de otimização deve refletir cinco propriedades estruturais do modelo: (i) dois objetivos conflitantes com naturezas distintas (f_1 contínuo/real em unidades de distância e f_2 estritamente inteiro e discreto); (ii) linearidade tanto nas funções objetivo quanto nas restrições; (iii) cardinalidade máxima da fronteira de Pareto limitada a, no máximo, oito pontos ($f_2 \in \{1, 2, \ldots, 8\}$); (iv) Ocupação de base e cota mínima de atendimento ($L = 4$); e (v) tempo de execução reduzido para viabilizar análises e apoio à decisão operacional.

Métodos de escalarização por soma ponderada ($\min f_1(x) + W f_2(y)$) exigem a calibração arbitrária de pesos W e são incapazes de identificar soluções não dominadas alojadas em porções

não convexas da fronteira discreta [2]. Por outro lado, como f_2 assume apenas valores inteiros no conjunto $\{1, \ldots, 8\}$, métodos baseados em decomposição exata por restrição (ε-restrito) podem varrer exaustivamente todos os níveis de f_2 em um número reduzido de subproblemas independentes [2]. Algoritmos evolutivos multiobjetivo (como NSGA-II, SPEA2 e MOEA/D) operam sobre populações e obtêm aproximações da fronteira em uma única execução [1, 3], mas necessitam de operadores de reparo ou penalização para evitar soluções inválidas perante as restrições de igualdade (4), (6) e de cota mínima (9).

3 Escolha principal: Método ε-restrito

Propõe-se como ferramenta principal o método ε-restrito acoplado a uma ferramenta determinística de Programação Linear Inteira Mista (MILP) [2]. A escolha justifica-se pelo fato de a variável de compromisso $f_2(y)$ admitir no máximo $s = 8$ valores inteiros viáveis. Em vez de aproximar a fronteira heuristicamente, resolve-se uma sequência de oito problemas mono-objetivo exatos parametrizados por $\varepsilon \in \{1, 2, \ldots, 8\}$:

$$\min_{x,y,h} \quad f_1(x) = \sum_{i \in I} \sum_{j \in J} d_{ij} x_{ij}, \tag{14}$$

$$\text{sujeito a} \quad (x, y, h) \text{ satisfazer (3)–(11)}, \tag{15}$$

$$f_2(y) = \sum_{j \in J} \sum_{k \in K} y_{jk} \leq \varepsilon. \tag{16}$$

Na versão estrita para mapeamento pontual, a inequação (16) pode ser fixada como igualdade ($f_2(y) = \varepsilon$) ou monitorada para filtrar soluções fracamente dominadas caso o otimizador utilize menos equipes do que o teto ε imposto.

3.1 Redução de simetria e fortalecimento da formulação

Na formulação original (3)–(11), as equipes $k \in K$ são homogêneas, o que introduz simetria de permutação ($8! = 40.320$ representações equivalentes para um mesmo subconjunto de 8 equipes ativas). Para acelerar a convergência do método de resolução MILP, aplicam-se duas técnicas de fortalecimento algébrico:

1. **Quebra de simetria e desagregação de restrições lógicas:** Ordenam-se os índices das equipes ativas impondo $\sum_{j \in J} y_{j,k} \geq \sum_{j \in J} y_{j,k+1}$ para $k = 1, \ldots, s-1$, eliminando permutações redundantes na árvore de busca. Além disso, a manutenção de restrições por ativo e base gera cortes mais fortes na relaxação linear do algoritmo de *Branch-and-Cut*.

2. **Agregação de índice quando equipes não dividem a mesma base:** Sob a premissa operacional de no máximo uma equipe por base ($\sum_{k \in K} y_{jk} \leq 1$), define-se a variável agregada de ativação de base $z_j = \sum_{k \in K} y_{jk} \in \{0, 1\}$. Nesse caso particular, a atribuição ativo-equipe h_{ik} torna-se diretamente determinada por x_{ij}, reduzindo o problema para $1.750 + 14 = 1.764$ variáveis binárias e substituindo (8)–(9) diretamente por:

$$4z_j \leq \sum_{i \in I} x_{ij}, \quad x_{ij} \leq z_j, \quad \forall i \in I, \ \forall j \in J. \tag{17}$$

Ambas as formulações (completa com 2.862 variáveis e reduzida com 1.764 variáveis) serão avaliadas no protocolo experimental para comprovar a equivalência exata das soluções ótimas.

3.2 Arquitetura de resolução matricial e paralelização

A implementação computacional da abordagem principal estrutura o problema no formato matricial padrão de Programação Linear Inteira Mista ($l_b \leq Av \leq u_b$, onde $v \in \{0,1\}^{2862}$ concatena os vetores de x_{ij}, y_{jk} e h_{ik}). A resolução apoia-se em algoritmos exatos de *Branch-and-Cut* combinados com relaxações lineares via método Simplex Dual e geração de planos de corte.

Como os subproblemas (14)–(16) para diferentes valores de $\varepsilon \in \{1, \ldots, 8\}$ são matematicamente independentes, a ferramenta emprega uma arquitetura de execução paralela em dois níveis: (i) paralelismo de tarefas, distribuindo os 8 subproblemas simultaneamente entre diferentes núcleos de processamento; e (ii) paralelismo interno na exploração da árvore de busca de cada subproblema MILP. O algoritmo segue sete etapas:

1. Carregar os registros de dados e estruturar a matriz de distâncias $D \in \mathbb{R}^{125\times 14}$.
2. Verificar a viabilidade aritmética da cota mínima ($L = 4 \leq \lfloor 125/\varepsilon \rfloor$, satisfeita para todo $\varepsilon \leq 8$).
3. Instanciar a execução paralela para os limites $\varepsilon \in \{8, 7, 6, 5, 4, 3, 2, 1\}$.
4. Em cada instância, montar a estrutura matricial esparsa das variáveis binárias x_{ij}, y_{jk}, h_{ik} e das restrições (3)–(11) acrescidas do limite (16) e das restrições de quebra de simetria.
5. Executar a ferramenta de otimização MILP até atingir otimalidade global.
6. Extrair os valores ótimos (f_1^*, f_2^*) e as matrizes de decisão correspondentes (x^*, y^*, h^*).
7. Filtrar eventuais soluções fracamente dominadas (caso reduções de ε mantenham f_2^* inalterado) e consolidar a Fronteira de Pareto exata.

4 Método comparativo: NSGA-II com Codificação Discreta e Reparo

Para atender aos requisitos de avaliação de metaheurísticas populacionais e dispor de um método comparativo escalável para instâncias de maior porte, propõe-se o algoritmo evolutivo *Non-dominated Sorting Genetic Algorithm II* (NSGA-II), introduzido por Deb et al. [1].

4.1 Representação cromossômica e decodificação

A aplicação ingênua de representação binária pura de 2.862 bits no NSGA-II produziria quase 100% de indivíduos inviáveis durante o cruzamento e a mutação, violando as restrições de atribuição única (4) e (6). Para contornar essa limitação estrutural, adota-se uma codificação híbrida compacta ou baseada em vetores inteiros:

- Cada indivíduo representa um vetor de ativação e localização de equipes $g = (g_1, g_2, \ldots, g_s) \in \{0, 1, \ldots, m\}^s$, onde $g_k = 0$ indica que a equipe k não é utilizada ($\sum_{j\in J} y_{jk} = 0$) e $g_k = j \in \{1, \ldots, 14\}$ indica que a equipe k está alocada na base j ($y_{jk} = 1$). Essa codificação satisfaz automaticamente (3), (10) e (11).
- Dado o conjunto de equipes ativas e suas bases, um operador de decodificação atribui cada ativo $i \in I$ à base ocupada mais próxima, determinando x_{ij} e h_{ik} de modo a satisfazer construtivamente (4), (5), (6), (7) e (8).

4.2 Tratamento da restrição de carga mínima e operadores

A única restrição passível de violação após a decodificação é a cota mínima de $L = 4$ ativos por equipe ativa (9). O tratamento dessa restrição combina duas abordagens complementares [1, 4]:

1. **Operador de reparo heurístico:** Se uma equipe ativa k^* receber menos de 4 ativos na atribuição por menor distância, realocam-se os ativos mais próximos pertencentes a equipes com folga ($\sum_i h_{ik} > 4$) para a base da equipe k^* até atingir 4 ativos, ou desativa-se a equipe k^* ($g_{k^*} \leftarrow 0$) transferindo seus ativos remanescentes.

2. **Violação normalizada por dominância restrita (*Feasibility-First*):** Caso o reparo não seja aplicado, quantifica-se a violação total de capacidade mínima e de ausência de equipes ativas:

$$V(x, y, h) = \sum_{k \in K} \max \left\{ 0,\ 4 \sum_{j \in J} y_{jk} - \sum_{i \in I} h_{ik} \right\} + \max \left\{ 0,\ 1 - \sum_{j \in J} \sum_{k \in K} y_{jk} \right\}. \qquad (18)$$

No torneio binário do NSGA-II, soluções viáveis ($V = 0$) dominam quaisquer soluções inviáveis ($V > 0$); entre duas soluções inviáveis, vence a de menor V; e entre soluções viáveis, aplica-se a classificação por não dominância nos objetivos (f_1, f_2) seguida pela distância de aglomeração (*crowding distance*) [1].

5 Configuração experimental e protocolo de avaliação

A matriz de distâncias $D \in \mathbb{R}^{125 \times 14}$ é obtida diretamente dos dados fornecidos para os pares ativo-base, mantendo estrita consistência entre os dois métodos avaliados. Esta entrega descreve o projeto metodológico e o protocolo da ferramenta, não reportando resultados computacionais já executados.

Tabela 1: Configuração proposta para os experimentos computacionais.

Elemento / Parâmetro	**Especificação Proposta**
Dimensões da Instância de Teste	$n = 125$ ativos, $m = 14$ bases, $s = 8$ equipes, $L = 4$
Método principal (Exato)	Método ε-restrito paralelo com MILP ($\varepsilon \in \{1, \ldots, 8\}$)
Critério de parada (Método principal)	Tolerância de otimalidade (ótimo global)
Método comparativo (Metaheurística)	NSGA-II com codificação inteira-discreta e reparo
População do NSGA-II	100 indivíduos
Número máximo de gerações	200 gerações
Execuções independentes (NSGA-II)	20 sementes aleatórias distintas
Métricas de comparação	Hipervolume, IGD, desvio percentual ótimo e tempo (s)

A avaliação comparativa entre o método ε-restrito exato e o NSGA-II conterá quatro indicadores quantitativos:

- **Exatidão e Cobertura da Fronteira:** Como o método ε-restrito via MILP determina a Fronteira de Pareto exata $\mathcal{P}^*$, será medido o desvio percentual relativo de distância $\Delta f_1(\varepsilon) = (f_1^{\text{NSGA-II}}(\varepsilon) - f_1^*(\varepsilon))/f_1^*(\varepsilon)$ para cada número de equipes $\varepsilon \in \{1, \ldots, 8\}$.

- **Hipervolume (HV) e Distância Geracional Invertida (IGD):** Calculados sobre os objetivos normalizados a partir da fronteira de referência exata $\mathcal{P}^*$, avaliando a convergência e a dispersão das 20 execuções independentes do NSGA-II [3].

- **Desempenho Computacional:** Comparação do tempo de processamento entre a execução sequencial e paralela do método ε-restrito em matrizes esparsas, a enumeração exaustiva das 12.910 combinações de bases (para o caso sem repetição de base) e o custo computacional médio das execuções do NSGA-II.

- **Análise Operacional e de Sensibilidade:** Visualização da distribuição espacial das alocações ativo-base para $k = 1, \ldots, 8$ equipes e avaliação do impacto da variação do parâmetro $\eta \in \{0,1;\ 0,2;\ 0,4\}$ ($L \in \{2, 4, 7\}$) sobre o compromisso entre distância total e número de equipes.

6 Justificativa final

A adoção do método ε-restrito acoplado a ferramentas de Programação Linear Inteira Mista (MILP) como abordagem principal de otimização decorre diretamente da estrutura matemática do problema de monitoramento de ativos formulado na Entrega #1. Por se tratar de um modelo inteiramente linear com variáveis binárias e cuja segunda função objetivo (f_2, número de equipes) é discreta e limitada a apenas oito valores inteiros ($1 \leq f_2 \leq 8$), a resolução dos oito subproblemas independentes em paralelo fornece a Fronteira de Pareto globalmente ótima e exata em reduzido tempo computacional [2]. Essa estratégia elimina a necessidade de ajustar pesos arbitrários previamente e garante que nenhuma solução eficiente da fronteira discreta seja omitida.

A manutenção do NSGA-II com codificação inteira-discreta e tratamento de restrições como método comparativo cumpre um papel metodológico essencial [1, 4, 5]: permite contrastar o paradigma evolutivo populacional frente à programação matemática exata, avaliando a eficácia de operadores de reparo e penalização sob a restrição de cota mínima ($L = 4$ ativos por equipe) e oferecendo uma estrutura flexível para extensões futuras do problema nos quais um aumento substancial no número de bases, equipes ou ativos geraria uma explosão combinatória intratável para métodos exatos, além da incorporação de funções objetivas não lineares ou incertezas operacionais.

Referências

[1] DEB, K.; PRATAP, A.; AGARWAL, S.; MEYARIVAN, T. A fast and elitist multiobjective genetic algorithm: NSGA-II. **IEEE Transactions on Evolutionary Computation**, v. 6, n. 2, p. 182–197, 2002. DOI: 10.1109/4235.996017.

[2] MAVROTAS, G. Effective implementation of the ε-constraint method in multi-objective mathematical programming problems. **Applied Mathematics and Computation**, v. 213, n. 2, p. 455–465, 2009. DOI: 10.1016/j.amc.2009.03.037.

[3] ZITZLER, E.; DEB, K.; THIELE, L. Comparison of multiobjective evolutionary algorithms: empirical results. **Evolutionary Computation**, v. 8, n. 2, p. 173–195, 2000. DOI: 10.1162/106365600568202.

[4] COELLO COELLO, C. A. Theoretical and numerical constraint-handling techniques used with evolutionary algorithms: a survey of the state of the art. **Computer Methods in Applied Mechanics and Engineering**, v. 191, n. 11–12, p. 1245–1287, 2002. DOI: 10.1016/S0045-7825(01)00323-1.

[5] BLANK, J.; DEB, K. pymoo: Multi-objective optimization in Python. **IEEE Access**, v. 8, p. 89497–89509, 2020. DOI: 10.1109/ACCESS.2020.2990567.