Monitoramento de Ativos

Entrega #2 – Ferramenta de Otimização: Algoritmo de Solução

Pedro Nunes, Fabio Xavier, Djalma Junior, Nikolas Barbosa, Pedro Marinho

EEE910 – Otimização Multiobjetivo

Outubro de 2026

Problema de otimização considerado

Conjuntos e dimensões

- $I = \{1, \ldots, 125\}$ ativos ($n = 125$)
- $J = \{1, \ldots, 14\}$ bases ($m = 14$)
- $K = \{1, \ldots, 8\}$ equipes ($s = 8$)
- $125 \times 14 = 1.750$ distâncias d_{ij}

Variáveis binárias (2.862 no total)

- $x_{ij} \in \{0, 1\}$: ativo i na base j (1.750)
- $y_{jk} \in \{0, 1\}$: equipe k na base j (112)
- $h_{ik} \in \{0, 1\}$: ativo i na equipe k (1.000)

Funções objetivo conflitantes

$$\min \quad f_1(x) = \sum_{i \in I} \sum_{j \in J} d_{ij} x_{ij}$$

$$\min \quad f_2(y) = \sum_{j \in J} \sum_{k \in K} y_{jk}$$

Cota mínima por equipe ativa

$$L = \left\lceil \frac{0,2 \cdot 125}{8} \right\rceil = 4 \text{ ativos}$$

$$\sum_{i \in I} h_{ik} \geq 4 \sum_{j \in J} y_{jk}, \quad \forall k \in K$$

Estrutura do espaço de busca e critérios de escolha

Alocação espacial sem sequenciamento de rotas

- Ordem de visita não é considerada $\Rightarrow$ evita explosão fatorial ($n!$).
- Sem repetição de bases ($\sum_{k \in K} y_{jk} \leq 1$), o total de configurações de bases é:

$$N_{\text{comb}} = \sum_{\varepsilon=1}^{8} \binom{14}{\varepsilon} = 14 + 91 + 364 + 1.001 + 2.002 + 3.003 + 3.432 + 3.003 = 12.910$$

Por que não atribuição simples?

A cota mínima ($L = 4$) impede alocar cada ativo à base mais próxima se uma base isolada atrair menos de 4 ativos.

Propriedades-chave do modelo

- Modelo 100% linear binário;
- $f_2 \in \{1, \ldots, 8\}$ (máximo 8 pontos na fronteira de Pareto).

Escolha principal: Método ε-restrito com MILP

- Soma ponderada ($\min f_1 + Wf_2$) exige calibração de pesos e perde soluções em regiões não convexas da fronteira discreta.
- Como f_2 admite apenas 8 valores inteiros, resolve-se exatamente cada nível $\varepsilon \in \{1, 2, \ldots, 8\}$ via Programação Linear Inteira Mista (MILP):

Subproblema parametrizado por $\varepsilon \in \{1, \ldots, 8\}$

$$\begin{aligned} \min_{x,y,h} \quad & f_1(x) = \sum_{i \in I} \sum_{j \in J} d_{ij} x_{ij} \\ \text{sujeito a} \quad & (x, y, h) \text{ satisfazer as restrições ,} \\ & f_2(y) = \sum_{j \in J} \sum_{k \in K} y_{jk} \leq \varepsilon \end{aligned}$$

- A inequação $f_2(y) \leq \varepsilon$ pode ser fixada como igualdade ou filtrada para eliminar soluções fracamente dominadas.

Redução de simetria e fortalecimento da formulação

Equipes $k \in K$ homogêneas geram simetria de permutação ($8! = 40.320$ representações equivalentes). Aplicam-se duas técnicas algébricas:

1. Quebra de simetria

Ordenação dos índices das equipes ativas:

$$\sum_{j \in J} y_{j,k} \geq \sum_{j \in J} y_{j,k+1}, \quad k = 1, \ldots, s-1$$

- Elimina permutações redundantes na árvore de *Branch-and-Cut*;
- Restrições desagregadas geram cortes lineares mais fortes.

2. Agregação por base (z_j)

Com até 1 equipe por base ($z_j = \sum_{k \in K} y_{jk} \in \{0, 1\}$):

$$4z_j \leq \sum_{i \in I} x_{ij}, \quad x_{ij} \leq z_j$$

- Dispensa h_{ik} explicitamente;
- Reduz de **2.862** para **1.764** variáveis binárias.

Arquitetura de resolução matricial e paralelização

- Formulação matricial esparsa padrão: $l_b \leq Av \leq u_b$, com $v \in \{0,1\}^{2862}$ concatenando os vetores (x_{ij}, y_{jk}, h_{ik}).
- Resolução via *Branch-and-Cut* com relaxações lineares (Simplex Dual).
- **Paralelismo em 2 níveis:** (i) distribuição simultânea dos 8 subproblemas ($\varepsilon = 1, \ldots, 8$) e (ii) paralelismo interno na árvore de busca MILP.

Fluxo algorítmico em 7 etapas

1. Carregar dados e estruturar a matriz de distâncias $D \in \mathbb{R}^{125\times14}$;
2. Verificar viabilidade aritmética da cota mínima ($L = 4 \leq \lfloor 125/\varepsilon \rfloor$);
3. Instanciar execução paralela para $\varepsilon \in \{8, 7, 6, 5, 4, 3, 2, 1\}$;
4. Montar matriz com as restrições, limite ε e quebra de simetria;
5. Executar otimização MILP até otimalidade global;
6. Extrair valores ótimos (f_1^*, f_2^*) e matrizes (x^*, y^*, h^*);
7. Filtrar soluções fracamente dominadas e consolidar a Fronteira de Pareto exata.

Método comparativo: NSGA-II Discreto com Reparo

Uma representação binária pura de 2.862 bits geraria indivíduos inviáveis nas restrições de atribuição única.

Representação cromossômica inteira e decodificação

- **Cromossomo:** vetor inteiro $g = (g_1, g_2, \ldots, g_s) \in \{0, 1, \ldots, 14\}^8$:
  - $g_k = 0 \Rightarrow$ equipe k inativa ($\sum_{j \in J} y_{jk} = 0$);
  - $g_k = j \in \{1, \ldots, 14\} \Rightarrow$ equipe k alocada na base j ($y_{jk} = 1$).
- **Decodificação:** cada ativo $i \in I$ é atribuído à base ocupada mais próxima, satisfazendo construtivamente (R1)–(R6), (R8) e (R9).

1. Operador de reparo heurístico
Equipes com menos de 4 ativos recebem ativos próximos de equipes com folga ($\sum_i h_{ik} > 4$) ou são desativadas ($g_{k^*} \leftarrow 0$).

2. Dominância restrita (*Feasibility-First*)
Penaliza a violação de cota mínima $V(x, y, h)$; soluções viáveis ($V = 0$) dominam inviáveis ($V > 0$).

Configuração experimental proposta

- Matriz de distâncias $D \in \mathbb{R}^{125\times 14}$ mantida idêntica entre os dois métodos.
- Proposta metodológica e protocolo da ferramenta (sem execução de resultados nesta etapa).

Elemento / Parâmetro	**Especificação Proposta**
Dimensões da Instância de Teste	$n = 125$ ativos, $m = 14$ bases, $s = 8$ equipes, $L = 4$
Método principal (Exato)	Método ε-restrito paralelo com MILP ($\varepsilon \in \{1, \ldots, 8\}$)
Critério de parada (Principal)	Tolerância de otimalidade (ótimo global)
Método comparativo (Metaheurística)	NSGA-II com codificação inteira-discreta e reparo
População do NSGA-II	100 indivíduos
Número máximo de gerações	200 gerações
Execuções independentes (NSGA-II)	20 sementes aleatórias distintas
Métricas de comparação	Hipervolume, IGD, desvio percentual ótimo e tempo (s)

Protocolo de avaliação e indicadores

1. Exatidão e Cobertura

Desvio relativo frente à fronteira exata $\mathcal{P}^*$:

$$\Delta f_1(\varepsilon) = \frac{f_1^{\text{NSGA-II}}(\varepsilon) - f_1^*(\varepsilon)}{f_1^*(\varepsilon)}$$

para cada $\varepsilon \in \{1, \ldots, 8\}$.

2. Convergência Multiobjetivo

Cálculo de **Hipervolume (HV)** e **IGD** sobre objetivos normalizados nas 20 execuções do NSGA-II.

3. Desempenho Computacional

Comparação de tempo entre:

- ε-restrito sequencial vs. paralelo;
- Enumeração das 12.910 combinações;
- Execuções do NSGA-II.

4. Sensibilidade Operacional

Mapas espaciais de alocação ($k = 1, \ldots, 8$) e variação de $\eta \in \{0,1;\ 0,2;\ 0,4\}$ ($L \in \{2, 4, 7\}$).

Justificativa final

Método ε-restrito com MILP (Abordagem Principal)

- Explora diretamente a linearidade do modelo e a natureza discreta e limitada do segundo objetivo ($1 \leq f_2 \leq 8$);
- Resolução paralela de 8 subproblemas garante a **Fronteira de Pareto globalmente ótima** sem ajuste arbitrário de pesos.

NSGA-II com Codificação Discreta e Reparo (Abordagem Comparativa)

- Contrasta a otimização evolutiva populacional com a programação matemática exata sob a restrição de capacidade mínima ($L = 4$);
- Garante **escalabilidade futura** caso o número de bases, equipes ou ativos aumente substancialmente (explosão combinatória) ou sejam incluídas funções não lineares e incertezas operacionais.

Referências bibliográficas

DEB, K.; PRATAP, A.; AGARWAL, S.; MEYARIVAN, T. A fast and elitist multiobjective genetic algorithm: NSGA-II. **IEEE Transactions on Evolutionary Computation**, v. 6, n. 2, p. 182–197, 2002. DOI: 10.1109/4235.996017.

MAVROTAS, G. Effective implementation of the ε-constraint method in multi-objective mathematical programming problems. **Applied Mathematics and Computation**, v. 213, n. 2, p. 455–465, 2009. DOI: 10.1016/j.amc.2009.03.037.

ZITZLER, E.; DEB, K.; THIELE, L. Comparison of multiobjective evolutionary algorithms: empirical results. **Evolutionary Computation**, v. 8, n. 2, p. 173–195, 2000. DOI: 10.1162/106365600568202.

COELLO COELLO, C. A. Theoretical and numerical constraint-handling techniques used with evolutionary algorithms: a survey of the state of the art. **Computer Methods in Applied Mechanics and Engineering**, v. 191, n. 11–12, p. 1245–1287, 2002. DOI: 10.1016/S0045-7825(01)00323-1.

BLANK, J.; DEB, K. pymoo: Multi-objective optimization in Python. **IEEE Access**, v. 8, p. 89497–89509, 2020. DOI: 10.1109/ACCESS.2020.2990567.