Otimização Multiobjetivo da Manutenção Preventiva de Ativos

Entrega #2 – Ferramenta de Otimização: Algoritmo de Solução

Pedro Nunes Fabio Xavier Djalma Junior Nikolas Barbosa

Pedro Marinho

EEE910 – Otimização Multiobjetivo
Outubro de 2026

Resumo

Esta entrega discute e justifica a escolha do algoritmo de solução para o modelo formulado na Entrega #1. Recomenda-se o algoritmo evolutivo NSGA-II como método principal para aproximação da fronteira de Pareto e o método ε-constraint como procedimento comparativo. São descritos a codificação das soluções, a avaliação dos objetivos, o tratamento das restrições, os operadores evolutivos e um protocolo de experimentação reprodutível com dados demonstrativos e sintéticos associados ao IBM Maximo. Esta entrega constitui uma proposta metodológica; não apresenta resultados computacionais já executados.

1 Problema de otimização considerado

Na Entrega #1, a variável de decisão T_i representa o intervalo, em dias, entre duas intervenções preventivas no ativo $i \in I$, com $n = |I|$ ativos. Busca-se maximizar o intervalo preventivo médio e minimizar o custo anual esperado de intervenções preventivas e corretivas, respectivamente:

$$\max \quad f_1(\mathbf{T}) = \frac{1}{n} \sum_{i \in I} T_i, \tag{1}$$

$$\min \quad f_2(\mathbf{T}) = D \sum_{i \in I} \left[\frac{C_i^P}{T_i} + \frac{C_i^C T_i^{\beta_i - 1}}{\eta_i^{\beta_i}} \right]. \tag{2}$$

O custo esperado deriva da hipótese de intervenções preventivas com restauração da idade de confiabilidade e reparos corretivos mínimos entre preventivas. O histórico de falhas é representado por um processo de Poisson não homogêneo de lei de potência, com parâmetros $\eta_i > 0$ e $\beta_i > 1$ no experimento sintético.

As restrições definidas na Entrega #1 são:

$$T_i^{\min} \le T_i \le T_i^{\max}, \qquad \forall i \in I, \tag{3}$$

$$1 - \exp\left[-\left(\frac{T_i}{\eta_i}\right)^{\beta_i}\right] \le p_i^{\max}, \qquad \forall i \in I, \tag{4}$$

$$D \sum_{i \in I} \left[\frac{h_i^P}{T_i} + \frac{h_i^C T_i^{\beta_i - 1}}{\eta_i^{\beta_i}}\right] \le H, \tag{5}$$

$$f_2(\mathbf{T}) \le B. \tag{6}$$

com $T_i > 0$. Não se impõe limite inferior baseado na periodicidade de custo mínimo. A viabilidade deve ser examinada tanto para os limites individuais como para orçamento e capacidade. O conflito entre os objetivos é avaliado nas regiões admissíveis da instância e não garantido ponto a ponto.

2 Critérios para escolha do algoritmo

A escolha do método deve refletir características do problema: (i) dois objetivos potencialmente conflitantes em unidades distintas (dias e R$/ano); (ii) n variáveis contínuas e positivas; (iii) funções e restrições não lineares; (iv) limites de confiabilidade individuais e restrições acopladas de capacidade e orçamento; e (v) necessidade de apresentar ao decisor várias políticas admissíveis, em vez de uma única solução definida previamente por pesos.

Métodos baseados em somas ponderadas poderiam combinar os objetivos em uma função escalar; entretanto, exigiriam estabelecer pesos antes de explorar a fronteira e podem deixar de encontrar regiões não convexas da fronteira de Pareto. Métodos ε-constraint exploram múltiplos compromissos resolvendo repetidamente problemas mono-objetivo [2]. Algoritmos evolutivos multiobjetivo, por sua vez, trabalham com uma população de candidatos e podem aproximar diversas soluções não dominadas em uma execução [1, 3].

3 Escolha principal: NSGA-II

O *Non-dominated Sorting Genetic Algorithm II* (NSGA-II), introduzido por Deb et al. [1], foi escolhido como método principal por três características: classificação rápida por níveis de não dominância, seleção elitista e manutenção da diversidade de soluções por distância de aglomeração (*crowding distance*). Como metaheurística populacional, aceita avaliação direta das expressões não lineares e não requer derivadas analíticas para executar a busca.

Para fins de implementação, os dois objetivos serão convertidos para minimização:

$$\mathbf{F}(\mathbf{T}) = \Big(- f_1(\mathbf{T}),\ f_2(\mathbf{T}) \Big). \tag{7}$$

Essa transformação preserva a relação de dominância original. Uma solução viável $\mathbf{T}^a$ domina outra solução viável $\mathbf{T}^b$ quando $F_j(\mathbf{T}^a) \le F_j(\mathbf{T}^b)$ para ambos os objetivos $j \in \{1, 2\}$, com desigualdade estrita para pelo menos um deles.

3.1 Representação e inicialização

Cada indivíduo corresponde a um vetor real

$$\mathbf{T} = (T_1, \ldots, T_n), \qquad T_i \in [L_i, U_i], \tag{8}$$

com limites individuais pré-processados:

$$L_i = T_i^{\min}, \tag{9}$$

$$U_i = \min\left\{T_i^{\max}, \eta_i[-\ln(1 - p_i^{\max})]^{1/\beta_i}\right\}. \tag{10}$$

Essa transformação incorpora analiticamente as restrições individuais (3) e (4). É necessário verificar $L_i \leq U_i$ para todo ativo. A inicialização pode usar amostragem uniforme nos intervalos $[L_i, U_i]$, complementada pela política vigente do Maximo quando viável. Os limites por si sós não garantem as restrições globais de equipe e orçamento.

3.2 Tratamento das restrições globais

As restrições remanescentes são expressas em termos de violação normalizada:

$$v_H(\mathbf{T}) = \max\left\{0, \frac{D\sum_i \left[h_i^P/T_i + h_i^C T_i^{\beta_i - 1}/\eta_i^{\beta_i}\right] - H}{H}\right\}, \tag{11}$$

$$v_B(\mathbf{T}) = \max\left\{0, \frac{f_2(\mathbf{T}) - B}{B}\right\}, \tag{12}$$

$$V(\mathbf{T}) = v_H(\mathbf{T}) + v_B(\mathbf{T}). \tag{13}$$

Na seleção, propõe-se utilizar o critério de *factibilidade primeiro*: (i) soluções viáveis são preferidas a inviáveis; (ii) entre soluções inviáveis, prefere-se a menor violação; (iii) entre soluções viáveis, aplicam-se dominância de Pareto e diversidade. Trata-se de uma estratégia de tratamento de restrições compatível com a literatura de algoritmos evolutivos [1, 4]. Caso não se encontre nenhuma solução viável, o algoritmo não deverá divulgar uma política inviável como recomendação; devem-se examinar os limites e os parâmetros do cenário.

3.3 Operadores e ciclo evolutivo

A configuração inicial proposta utiliza codificação real, seleção por torneio binário, cruzamento SBX (*simulated binary crossover*) e mutação polinomial, com reparação das variáveis aos respectivos limites individuais. Em cada geração, pais e descendentes são reunidos, classificados em frentes de não dominância e reduzidos à população desejada mediante seleção elitista e *crowding distance*.

1. Carregar os parâmetros sintéticos ou estimados a partir do histórico demonstrativo.
2. Verificar consistência das unidades, viabilidade dos limites individuais e existência de soluções viáveis.
3. Inicializar a população de vetores $\mathbf{T}$.

4. Calcular $(-f_1, f_2)$ e as violações de capacidade e orçamento.
5. Selecionar candidatos por factibilidade e não dominância.
6. Aplicar cruzamento e mutação, corrigindo intervalos fora dos limites.
7. Reunir pais e descendentes e selecionar a próxima geração com elitismo e diversidade.
8. Repetir até o critério de parada e exportar as soluções viáveis não dominadas.

O resultado esperado é uma *aproximação* da fronteira de Pareto, não uma certificação automática de ótimo global. A qualidade dessa aproximação será avaliada empiricamente.

4 Método comparativo: ε-constraint

Como comparação independente, propõe-se o método ε-constraint, discutido por Mavrotas [2]. Para uma sequência de limites ε_k de custo, resolve-se:

$$\max_{\mathbf{T}} \quad f_1(\mathbf{T}), \tag{14}$$

$$\text{sujeito a} \quad \mathbf{T} \text{ satisfazer (3)–(??)}, \tag{15}$$

$$f_2(\mathbf{T}) \leq \varepsilon_k. \tag{16}$$

Os valores ε_k devem ser escolhidos na faixa efetivamente viável do custo esperado; quando $\varepsilon_k < B$, a nova restrição é mais estrita que o limite orçamentário original. Cada subproblema pode ser resolvido com um otimizador não linear, com múltiplos pontos iniciais e checagem explícita das restrições. O uso de um otimizador local não garante encontrar o ótimo global, de forma que divergências entre os métodos devem ser investigadas, não interpretadas automaticamente como superioridade de um deles.

5 Configuração experimental e avaliação

O cenário inicial será composto por cerca de 100 ativos, distribuídos em cinco classes, com registros demonstrativos do Maximo e histórico sintético de aproximadamente cinco anos. Os parâmetros de custo e de falha serão identificados como demonstrativos ou simulados, de forma que não se atribua validade empírica aos resultados antes da aplicação em dados reais.

Esses valores são parâmetros experimentais iniciais, não resultados de calibração. Serão examinadas a convergência entre gerações, a repetibilidade entre sementes, a cobertura da fronteira e o custo computacional. Quando disponível uma referência apropriada e normalização consistente, poderá ser avaliado o hipervolume; para dois objetivos, também se pode comparar graficamente a qualidade e a dispersão das soluções não dominadas. O percentual de soluções viáveis deverá ser reportado separadamente.

A avaliação de utilidade prática comparará as periodicidades sugeridas com a política original do Maximo por meio do intervalo médio, custo total esperado, risco por ativo e horas de manutenção demandadas. Essas métricas serão calculadas sob o mesmo conjunto de parâmetros do cenário. A análise de sensibilidade variará custos corretivos, parâmetros de falha, orçamento, capacidade e limites de risco.

Tabela 1: Configuração inicial proposta para os experimentos (sujeita a ajuste).

Elemento	**Valor inicial proposto**
População do NSGA-II	100 indivíduos
Número máximo de gerações	300
Cruzamento SBX	Probabilidade 0,90
Mutação polinomial	Probabilidade $1/n$ por variável
Execuções independentes	20 sementes aleatórias
Variáveis de decisão	n intervalos reais
Método comparativo	ε-constraint

6 Justificativa final

A escolha do NSGA-II é adequada porque o trabalho tem duas funções objetivo potencialmente conflitantes, variáveis contínuas, avaliações não lineares e interesse explícito em obter múltiplas políticas de manutenção. O algoritmo permite explorar regiões distintas do compromisso entre custo e periodicidade sem exigir pesos definidos previamente, enquanto sua seleção elitista e preservação de diversidade favorecem uma representação abrangente das alternativas [1]. Sua disponibilidade na biblioteca `pymoo`, apresentada por Blank e Deb [5], favorece reprodutibilidade e futura integração a um processo de extração e parametrização com dados do Maximo.

O método ε-constraint será mantido como referência comparativa por explorar o problema com sucessivos limites de custo [2]. A combinação é metodologicamente mais sólida do que adotar o NSGA-II sem comparação; entretanto, a escolha definitiva dependerá dos experimentos. Como a formulação atual possui apenas n variáveis contínuas e funções conhecidas, métodos determinísticos podem apresentar desempenho competitivo. Portanto, não se afirma antecipadamente que o NSGA-II seja o algoritmo mais eficiente ou que encontre necessariamente a fronteira exata.

Referências

Referências

[1] DEB, K.; PRATAP, A.; AGARWAL, S.; MEYARIVAN, T. A fast and elitist multiobjective genetic algorithm: NSGA-II. *IEEE Transactions on Evolutionary Computation*, v. 6, n. 2, p. 182–197, 2002. DOI: 10.1109/4235.996017.

[2] MAVROTAS, G. Effective implementation of the ε-constraint method in multi-objective mathematical programming problems. *Applied Mathematics and Computation*, v. 213, n. 2, p. 455–465, 2009. DOI: 10.1016/j.amc.2009.03.037.

[3] ZITZLER, E.; DEB, K.; THIELE, L. Comparison of multiobjective evolutionary algorithms: empirical results. *Evolutionary Computation*, v. 8, n. 2, p. 173–195, 2000. DOI: 10.1162/106365600568202.

[4] COELLO COELLO, C. A. Theoretical and numerical constraint-handling techniques used with evolutionary algorithms: a survey of the state of the art. *Computer Methods in Applied Mechanics and Engineering*, v. 191, n. 11–12, p. 1245–1287, 2002. DOI: 10.1016/S0045-7825(01)00323-1.

[5] BLANK, J.; DEB, K. pymoo: Multi-objective optimization in Python. *IEEE Access*, v. 8, p. 89497–89509, 2020. DOI: 10.1109/ACCESS.2020.2990567.