Otimização Multiobjetivo da Manutenção Preventiva de Ativos

Entrega #2 – Formulação e algoritmo

Pedro Nunes Fabio Xavier Djalma Junior
Nikolas Barbosa Pedro Marinho

EEE910 – Otimização Multiobjetivo | Outubro de 2026

Problema de manutenção preventiva

Decisão central

Definir **a periodicidade de manutenção preventiva de cada ativo**, buscando equilíbrio entre **intervalos maiores** e **menor custo anual esperado**.

Contexto

- Preventivas frequentes aumentam intervenções planejadas.
- Preventivas espaçadas podem aumentar falhas corretivas.
- Avaliação anualizada, sem agendar ordens de serviço.

Hipóteses adotadas

- Preventiva perfeita; reparo corretivo mínimo.
- Falhas segundo NHPP/PLP, com $\beta_i > 1$.
- Dados demonstrativos e sintéticos; sem validação em campo.

(a) Parâmetros fixos: cadastro e confiabilidade

Conjunto e horizonte

$I = \{1, \ldots, n\}$	conjunto de ativos
n	número de ativos
D	dias da base anual (365)

Custos e horas por evento

C_i^P	custo preventivo (R$/interv.)
C_i^C	custo corretivo (R$/falha)
h_i^P	horas por preventiva
h_i^C	horas por corretiva

Falhas e limites individuais

$\eta_i > 0$	escala PLP (dias)
$\beta_i > 1$	forma PLP
$T_i^{\min}$	intervalo mínimo (dias)
$T_i^{\max}$	intervalo máximo (dias)
$p_i^{\max}$	prob. máxima de falha/ciclo

Limites globais

H	horas de equipe disponíveis/ano
B	orçamento esperado anual (R$)

Instância proposta: cerca de 100 ativos distribuídos em cinco classes.

(b) Variáveis de decisão

Uma variável para cada ativo $i \in I$

$$T_i = \text{intervalo entre duas preventivas no ativo } i \quad \text{(dias)}$$

Vetor a ser determinado

$$\mathbf{T} = (T_1, T_2, \ldots, T_n)$$

Importante

Custos, parâmetros de falha e limites são **entradas**; não são decisões.

- n variáveis reais e positivas.
- Intervalos inteiros: extensão futura.

(c) Objetivo f_1: ampliar a periodicidade

O primeiro objetivo maximiza o **intervalo preventivo médio** entre os ativos:

$$\max_{\mathbf{T}} \; f_1(\mathbf{T}) = \frac{1}{n} \sum_{i \in I} T_i$$

Interpretação

- Unidade: **dias por ativo**.
- Cada ativo recebe o mesmo peso na média.
- Maior f_1 significa preventivas mais espaçadas, **não necessariamente maior disponibilidade**.

(d) Objetivo f_2: reduzir o custo esperado

No processo de falhas PLP, o número esperado de ocorrências por ciclo é:

$$\mathbb{E}[N_i(T_i)] = \left(\frac{T_i}{\eta_i}\right)^{\beta_i}.$$

O segundo objetivo minimiza o custo total anualizado:

$$\min_{\mathbf{T}} \; f_2(\mathbf{T}) = D \sum_{i \in I} \left(\frac{C_i^P}{T_i} + \frac{C_i^C \, T_i^{\beta_i - 1}}{\eta_i^{\beta_i}} \right)$$

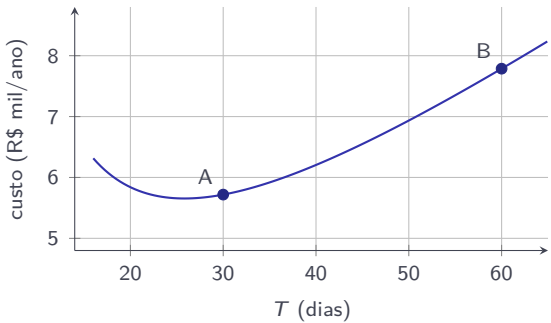
Parcela preventiva

$D\, C_i^P / T_i$: menos preventivas quando T_i aumenta.

Parcela corretiva

$D\, C_i^C \, T_i^{\beta_i - 1} / \eta_i^{\beta_i}$: cresce com T_i, para $\beta_i > 1$.

Conflito entre f_1 e f_2



Restrição R2: $T \leq 64{,}92$ dias para $p^{\max} = 10\%$ por ciclo.

Exemplo: um ativo

	A	B
T (dias)	30	60
Custo/ano	5.718	7.787
Risco/ciclo	2,22%	8,61%

Compromisso real

De A para B, f_1 melhora, mas f_2 piora: **nenhuma domina a outra**.

(e) Restrições individuais: R1 e R2

R1 – Limites técnicos de periodicidade

$$T_i^{\min} \leq T_i \leq T_i^{\max}, \quad \forall i \in I$$

Impede preventivas excessivamente frequentes ou excessivamente espaçadas.

R2 – Confiabilidade por ciclo

$$1 - \exp\left[-\left(\frac{T_i}{\eta_i}\right)^{\beta_i}\right] \leq p_i^{\max}, \quad \forall i \in I$$

Limita a **probabilidade de ao menos uma falha no ciclo**.

Na implementação, R1 e R2 definem os limites individuais da busca.

(e) Restrições globais: R3 e R4

R3 – Capacidade anual de equipe

$$D \sum_{i \in I} \left(\frac{h_i^P}{T_i} + \frac{h_i^C \, T_i^{\beta_i - 1}}{\eta_i^{\beta_i}} \right) \leq H$$

Horas esperadas para preventivas **e** corretivas não podem superar a capacidade.

R4 – Limite anual de orçamento

$$D \sum_{i \in I} \left(\frac{C_i^P}{T_i} + \frac{C_i^C \, T_i^{\beta_i - 1}}{\eta_i^{\beta_i}} \right) \leq B$$

O custo esperado respeita o teto financeiro, mesmo sendo minimizado em f_2.

R3 e R4 limitam valores esperados, não garantem o consumo realizado.

(f) Algoritmos de solução: NSGA-II e ε-constraint

Método principal: NSGA-II

- Codificação real: $\mathbf{T} = (T_1, \ldots, T_n)$.
- Otimiza $(-f_1, f_2)$ por **não dominância**.
- **Elitismo** e **crowding distance** preservam qualidade e diversidade.
- Restrições: viabilidade primeiro; depois dominância.

Comparação: ε-constraint

$$\max_{\mathbf{T}} \; f_1(\mathbf{T})$$

$$\text{s.a. R1–R4 e } f_2(\mathbf{T}) \leq \varepsilon$$

Gera alternativas impondo sucessivos tetos de custo.

Configuração inicial: 100 indivíduos, 300 gerações, SBX (0,90), mutação $(1/n)$, 20 sementes. Comparar fronteiras e política vigente.

Síntese da proposta

Formulação

- n intervalos preventivos contínuos, **dois objetivos** e **quatro restrições**.
- Compromisso entre **periodicidade média** e **custo anual esperado**.
- A fronteira deve ser **avaliada para cada instância**.

Próxima etapa

Executar NSGA-II com dados demonstrativos/sintéticos, verificar viabilidade e comparar soluções de Pareto com a política vigente e com ε-constraint.

Referências bibliográficas

- BARLOW, R.; HUNTER, L. *Optimum preventive maintenance policies*. Operations Research, 8(1), 90–100, 1960.
- RIGDON, S. E.; BASU, A. P. *The power law process: a model for the reliability of repairable systems*. Journal of Quality Technology, 21(4), 251–260, 1989.
- DEB, K. et al. *A fast and elitist multiobjective genetic algorithm: NSGA-II*. IEEE Transactions on Evolutionary Computation, 6(2), 182–197, 2002.
- MAVROTAS, G. *Effective implementation of the ε-constraint method in multi-objective mathematical programming problems*. Applied Mathematics and Computation, 213(2), 455–465, 2009.
- BLANK, J.; DEB, K. *pymoo: Multi-objective optimization in Python*. IEEE Access, 8, 89497–89509, 2020.
- NIST. *Engineering Statistics Handbook: Non-Homogeneous Poisson Process (NHPP) – Power Law*. `itl.nist.gov`.
- IBM. *Maximo Manage Documentation: Master PM frequency schedules; Work Orders module*. `ibm.com/docs`.